agent ai

tool usage가 활성화 되어있어야함.
아니라면 단순 프롬프트 체이닝() 혹은 **수동 툴-콜링(manual tool-use)** 패턴 사용

LangChain 기능	Tool Usage 필요 여부	설명
`LLMChain`, `PromptTemplate`	❌	단순 프롬프트 체이닝
`RetrievalQA`, `Vectorstore`	❌	문서 검색형 QA
`Agent` (ZeroShot, ReAct 등)	✅	외부 도구 호출 필요
`Tool`, `StructuredTool`	✅	함수/모듈 호출용

```
[사용자]
   ↓
[모델 A (OpenRouter free 모델)]
   → "다음 작업들을 JSON 리스트로 반환" (예: 어떤 툴을 써야 하는지)
   ↓
[너의 Python 코드]
   → JSON 파싱 → 그대로 실행 or 전달
   ↓
[모델 B 또는 외부 API 호출]
```

```
system_prompt = """
너는 도구 실행 계획만 세우는 assistant이다.
결과를 반드시 아래 JSON 형식으로만 출력하라.

형식:
{
  "actions": [
    {"tool": "summarize_schedule", "args": {"range": "tomorrow"}},
    {"tool": "send_kakao_message", "args": {"recipient": "me", "content": "회의
알림"}}
  ]
}
"""

user_prompt = "내 일정 정리하고, 카톡으로 내일 회의 알림 보내줘"

-
```

```
{
  "actions": [
    {"tool": "summarize_schedule", "args": {"range": "tomorrow"}},
    {"tool": "send_kakao_message", "args": {"recipient": "me", "content": "회의
알림"}}
  ]
}
```

```
-
```

```
reply = res.choices[0].message.content
actions = json.loads(reply)["actions"]

for act in actions:
    if act["tool"] == "summarize_schedule":
        result = summarize_schedule(**act["args"])
    elif act["tool"] == "send_kakao_message":
        send_kakao_message(**act["args"])
```

tool usage가 활성화 되어있어있더라도 n8n langchain langgraph 같은 걸 쓰지 않는다면 수동으로 위와같이 만들어 줘야함.

LLM

간단히 말하면 다음 단어(토큰) 맞추기
예를 들어 문장이 이렇게 있다고 해 보자:

> 오늘 날씨가 너무 좋아서 공원에 …

여기서 `…` 자리에 뭐가 올지 맞추는 모델

- “갔다”
- “산책하러”
- “나왔다”
- “가고 싶다”

이런 후보들 중에,
“이 앞의 문맥을 봤을 때, 어떤 단어가 가장 자연스러울까?”
→ 그 확률을 계산해서 제일 그럴듯한 걸 고르는 거지.

> 이 “다음 단어 맞추기”를 잘하는 모델 = LLM

컴퓨터는 글자를 직접 이해 못 하니까 **숫자**로 바꿔야 해.

1. **토큰(token)**
   - 문장을 잘게 쪼갠 단위
   - 단어일 수도 있고, 단어 조각(subword)일 수도 있음
   - 예:
     - “안녕하세요” → [“안”, “녕”, “하세요”] 같은 식으로 쪼개지기도 하고
     - “computer” → ["com", "put", "er"] 처럼 쪼개지기도 함
2. **숫자로 매핑 (토큰 ID)**
   - 각 토큰마다 번호를 붙임
   - 예: "안" → 1052, "녕" → 9843 이런 식
3. **임베딩(embedding)**
   - 토큰 ID 하나를 **긴 벡터(예: 길이 4096짜리 실수 배열)**로 바꿈
   - 예:
     - "고양이" → [0.12, -0.8, 0.03, …]
     - "강아지" → [0.11, -0.79, 0.02, …]
   - 비슷한 의미의 단어는 비슷한 방향의 벡터를 가지도록 학습됨

여기까지:
문장 → 토큰 → 숫자 ID → 고차원 벡터(임베딩)

이제 이 벡터들을 보고 “다음 단어 확률”을 계산해야 하는데,
여기서 쓰이는 구조가 **트랜스포머(Transformer)**야.

핵심 아이디어는 **Attention(어텐션)** 하나로 정리할 수 있어.

🔍 Attention: “어디를 얼마나 볼지” 정하는 메커니즘

예를 들어 문장:

> 어제 친구랑 고기를 먹었는데, **너무 맛있어서** 또 가고 싶다.

여기서 “맛있어서”라는 단어를 이해하려면:

- 앞에 나온 “고기”, “먹었는데” 같은 단어들이 중요하지?
- “어제”, “친구랑”은 상대적으로 덜 중요하고.

**Attention은 “현재 위치에서 문장 전체를 훑어보면서,
어떤 단어에 집중할지 가중치를 주는 연산”**이야.

느낌적으로:

- “맛있어서” → (고기: 0.7, 먹었는데: 0.6, 어제: 0.2, 친구랑: 0.3 …)

이렇게 **문장 안의 단어들끼리 서로를 바라보면서 의미를 주고받는** 구조가
트랜스포머의 핵심.

트랜스포머는 이런 블록을 **수십 개, 수백 개** 쌓아서:

- 단어 간 관계
- 문장 구조
- 긴 맥락 정보
  를 점점 더 풍부하게 섞음

4. 학습: 엄청나게 많이 "맞추기 문제"를 풀어본 상태

LLM이 "똑똑한 척" 할 수 있는 이유는 단 하나야.

> **인터넷 텍스트로 만든 거대한 코퍼스에서**
> **'다음 단어 맞추기' 문제를 기가 막히게 많이 풀어봤기 때문.**

학습 과정 아주 단순화하면:

1. 랜덤한 파라미터(가중치)로 시작
2. 문장 하나 뽑음:
   - "나는 오늘 학교에 갔다."
3. 앞에서부터 토큰 잘라가면서:
   - "나는" → 다음 단어 "오늘" 맞추기
   - "나는 오늘" → 다음 단어 "학교에" 맞추기
   - "나는 오늘 학교에" → "갔다" 맞추기
4. 매번 **모델이 예측한 확률 분포 vs 실제 정답** 비교해서
   - 오차(loss)를 계산
5. 그 오차를 줄이도록 **가중치(파라미터)를 조금씩 수정**
   - 이게 **역전파(backpropagation) + 경사 하강법(gradient descent)**

이걸:

- 수십억~수조 개 토큰에 대해
- 수천~수만 번 반복

→ 그러다 보면 모델 파라미터(수십억~수천억 개)가
"언어의 통계 패턴"을 몸에 익히게 되는 거지.

5. 추론(inference): 지금 우리가 대화할 때 벌어지는 일

우리가 지금 대화하는 시점에는 **학습은 이미 끝난 상태**고,
모델은 이렇게 동작해.

1. 너가 보낸 메시지 전체를 토큰화
2. 트랜스포머에 넣고 “다음 토큰 확률 분포”를 계산
3. 그 중에서
   - 가장 확률 높은 토큰을 고르거나
   - 샘플링(temperature, top-p, top-k 등)으로 살짝 랜덤 섞기도 하고
4. 그 토큰을 문장 뒤에 붙임
5. 새로 확장된 문장을 다시 넣고, 또 다음 토큰 예측
6. 이걸 멈출 때까지 반복 → **문장 한 줄 생성**

즉, **한 글자 한 글자(정확히는 한 토큰씩) 찍어내는 방식**이야.

6. “이해한다”는 말의 진짜 의미

LLM이 사람처럼 생각한다기보단, 솔직히 말하면:

> **“패턴 매칭 + 통계적 직감”**
> 이게 쌓여서

- 논리적으로 말하는 것처럼 보이고
- 수학 증명을 쓰고
- 코드도 짜고
- 너의 의도도 어느 정도 파악해.

근데 주의할 점:

- 진짜 세계 모델(물리적으로 세상이 어떻게 돌아가는지에 대한 명시적 시뮬레이터)이 아니라
- 학습 데이터에서 본 **텍스트의 패턴** 기반이란 점에서 한계가 있음
  - 헛소리(환각)
  - 숫자 계산 실수
  - 사실관계 틀리기도 함

7. 요약하면

한 줄로 요약하면 LLM은:

> **“많은 양의 텍스트를 먹고,**
> **‘다음에 올 단어를 맞추는’ 일을 반복 학습해서**
> **인간처럼 말하는 흉내내는 함수”**
> 조금 더 기술적으로는:
> **“토큰 시퀀스를 입력받아,**
> **다음 토큰의 확률 분포를 출력하는 거대한 트랜스포머 신경망”**

attention

다음 단어 예측 Loss를 최소화하는 방향으로 학습됨.

문장 예시:

> 나는 어제 친구랑 고기를 먹었다.

여기서 “먹었다”라는 단어가 “고기”에 중요한 attention을 두는 건
사람은 직관적으로 알지만
모델은 **이걸 스스로 “숫자 점수”로 만들도록 학습한다.**

```
import torch
import torch.nn as nn
import torch.nn.functional as F

class TinySelfAttention(nn.Module):
    def __init__(self, d_model):
        super().__init__()
        self.d_model = d_model

        # Q, K, V: 각각 (d_model → d_model)
        self.Wq = nn.Linear(d_model, d_model)
        self.Wk = nn.Linear(d_model, d_model)
        self.Wv = nn.Linear(d_model, d_model)

    def forward(self, x):
        # x shape = (N, d_model)
        Q = self.Wq(x)   # shape: (N, d_model)
        K = self.Wk(x)   # shape: (N, d_model)
        V = self.Wv(x)   # shape: (N, d_model)

        # Attention = softmax(QKᵀ / sqrt(d))
        attn_scores = (Q @ K.transpose(0, 1)) / (self.d_model ** 0.5)
        attn_probs = F.softmax(attn_scores, dim=-1)  # (N, N)

        # Weighted sum
        out = attn_probs @ V  # (N, d_model)
        return out


class TinyTransformerBlock(nn.Module):
    def __init__(self, d_model, hidden=1024):
        super().__init__()
        self.attn = TinySelfAttention(d_model)
        self.ffn = nn.Sequential(
```

```
            nn.Linear(d_model, hidden),
            nn.ReLU(),
            nn.Linear(hidden, d_model)
        )

    def forward(self, x):
        # x: (N, d_model)
        x = x + self.attn(x)   # residual
        x = x + self.ffn(x)    # residual
        return x


# --------------------------
# 사용 예시
# --------------------------

d_model = 32
model = TinyTransformerBlock(d_model)

# 10개의 토큰 (N=10)
x1 = torch.randn(10, d_model)
out1 = model(x1)
print(out1.shape)   # torch.Size([10, 32])

# 150개의 토큰 (N=150)
x2 = torch.randn(150, d_model)
out2 = model(x2)
print(out2.shape)   # torch.Size([150, 32])
```

⚙️ 2. Attention 점수는 이렇게 만들어짐

토큰마다 임베딩이 있지?
예:

- “나는” → 벡터 A
- “고기” → 벡터 B
- “먹었다” → 벡터 C
  이런 식.

Attention은 이 벡터들에서
3개의 새로운 벡터를 만든다:

- Query(q)
- Key(k)
- Value(v)

이 세 가지는 전부 **학습 가능한 선형변환(weight matrix)**로 만든다:

```
q = Wq * embedding
k = Wk * embedding
v = Wv * embedding
```

즉:
Attention에서 중요한 건 Query와 Key의 관계 (q·k 점수)

- Query: 지금 보고 있는 단어가 “무엇을 찾으려고 하는지”
- Key: 각 단어가 “나는 이런 정보를 가지고 있어요”라고 내놓는 명함 같은 것

q와 k를 내적하면 **두 단어의 관련성 점수 (similarity)**가 나와.

```
score = qᵀ * k
```

이걸 softmax로 정규화하면
각 단어에 대한 Attention weight (가중치)가 된다.

🔁 3. 그럼 이 q, k, v를 만드는 Wq, Wk, Wv는 어디서 나옴?

바로 **학습으로 만든다.**

이 세 개의 행렬(Wq, Wk, Wv)은 수십억 개의 파라미터 중 일부로서
다음 단어 예측 Loss를 최소화하는 방향으로 학습됨.

즉:

- “고기”와 “먹었다”가 중요한 관계인데
- Attention이 엉뚱하게 “나는”에 집중했다?

그러면 모델 예측이 틀릴 확률이 커져서
Loss가 크게 나오고 → 역전파 → Wq/Wk/Wv 수정됨

반대로,

- “먹었다”가 “고기” 또는 “친구랑”에 적절히 집중하면

- 다음 단어 예측이 잘 맞아 → Loss 작아짐
  → 가중치가 안정적으로 수렴함

트랜스포머

Autoregressive LM:

- attention: 지금 처리 중인 단어가 문장의 어떤 단어에 집중 해야 하는가?
- input -> encoder(vectorization attention) -> 문맥이 반영된 표현으로 바뀜
- -> decoder -> 이전 생성된 단어와 encoder를 참고해서 다음단어 예측
- -> output
- “문장 속에서 다음 단어를 맞히는 게임”을 반복하면서 언어의 문법, 문맥, 의미를 자연스럽게 배우는 모델이에요.

BERT:

- 문장 중간에 빈칸을 추론.

agent ai

chaining

- 순차적으로 gpt(gpt(gpt(A),B),C)해서 순차적으로 답변을 매개변수로 답을 구하는 형식
- 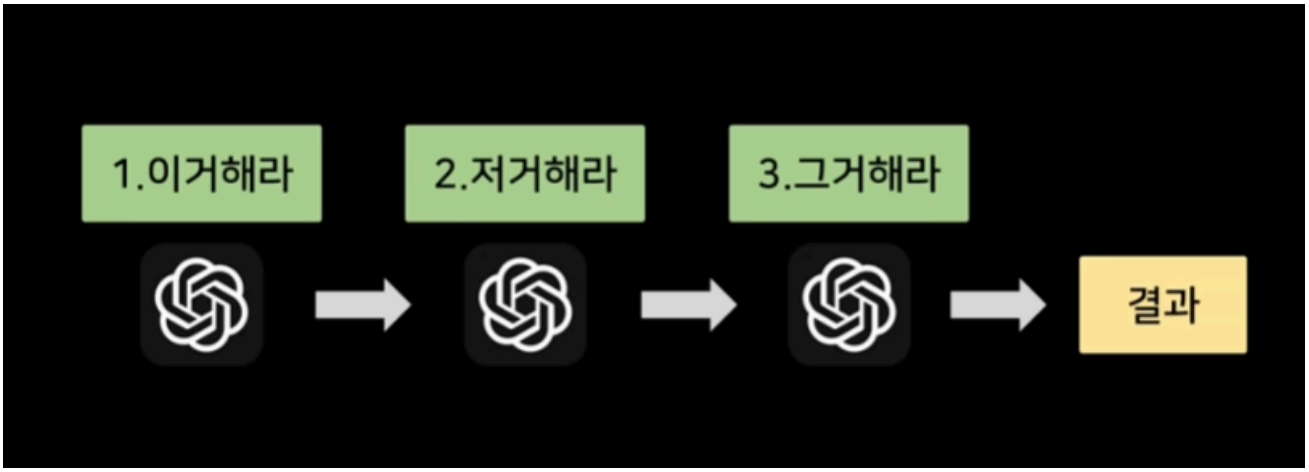

- 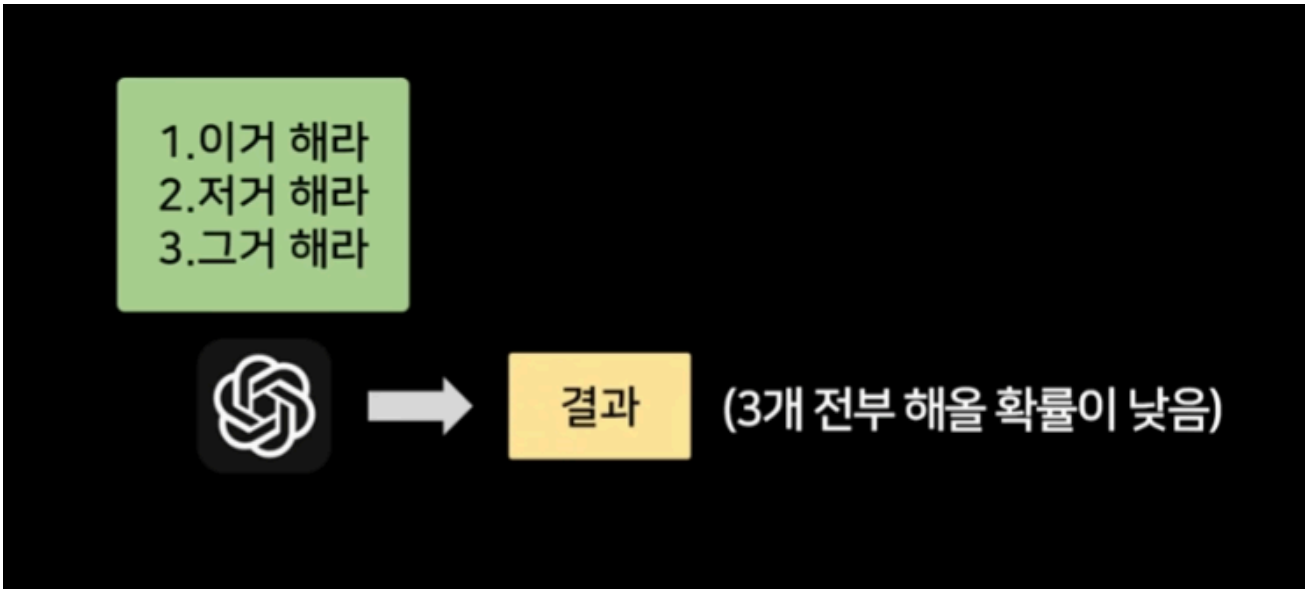

- 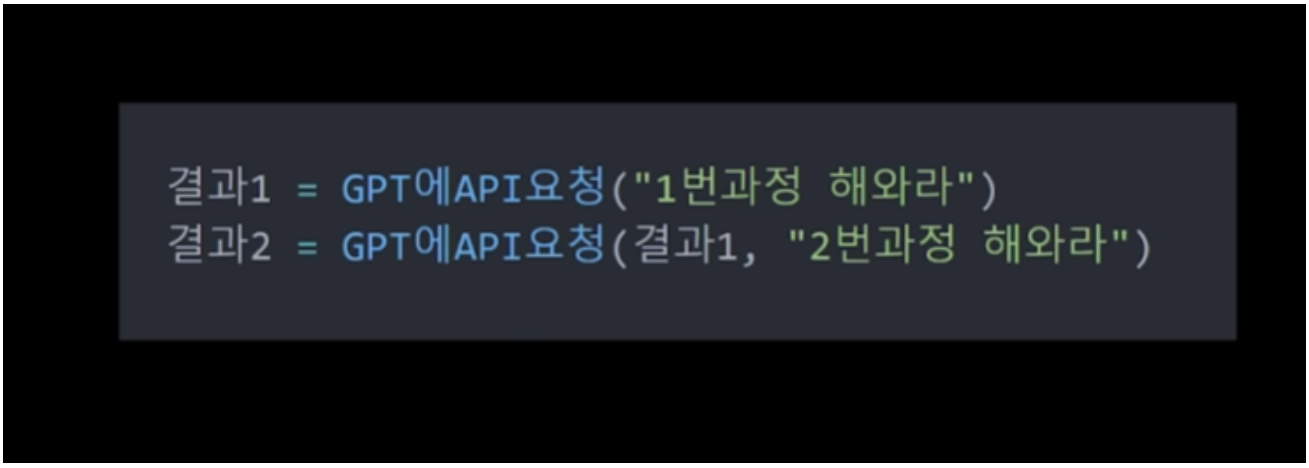

-

route

- 가이드 만듦
- 운영팀, 개발팀, 디자인팀 등
- 문장이 오면 어느 부서로 전달 할 지 정하고 실제로 거기에 맞게 보내서 추론시키기

- 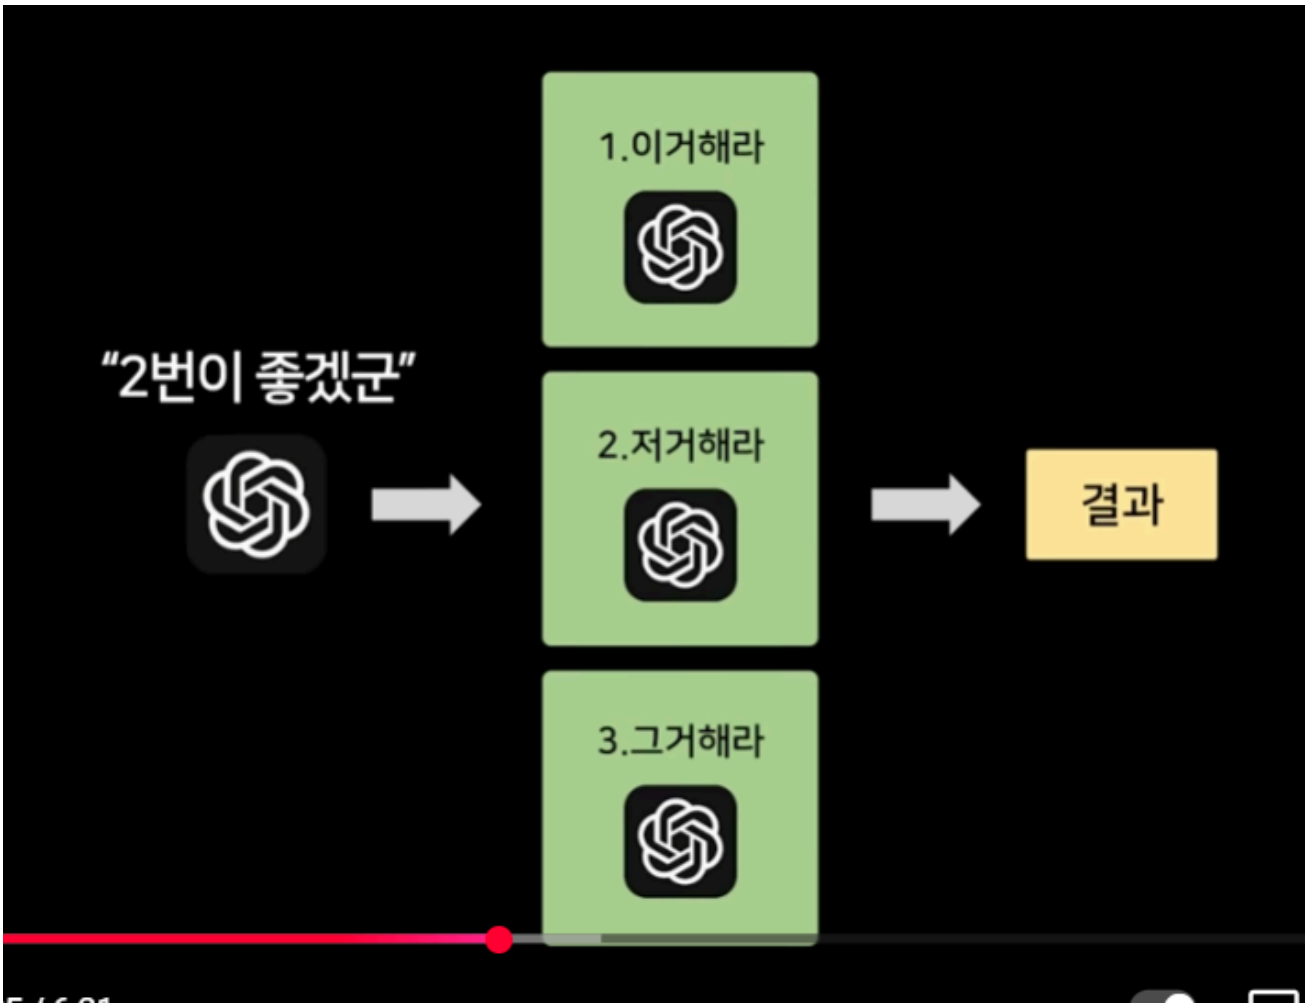

- 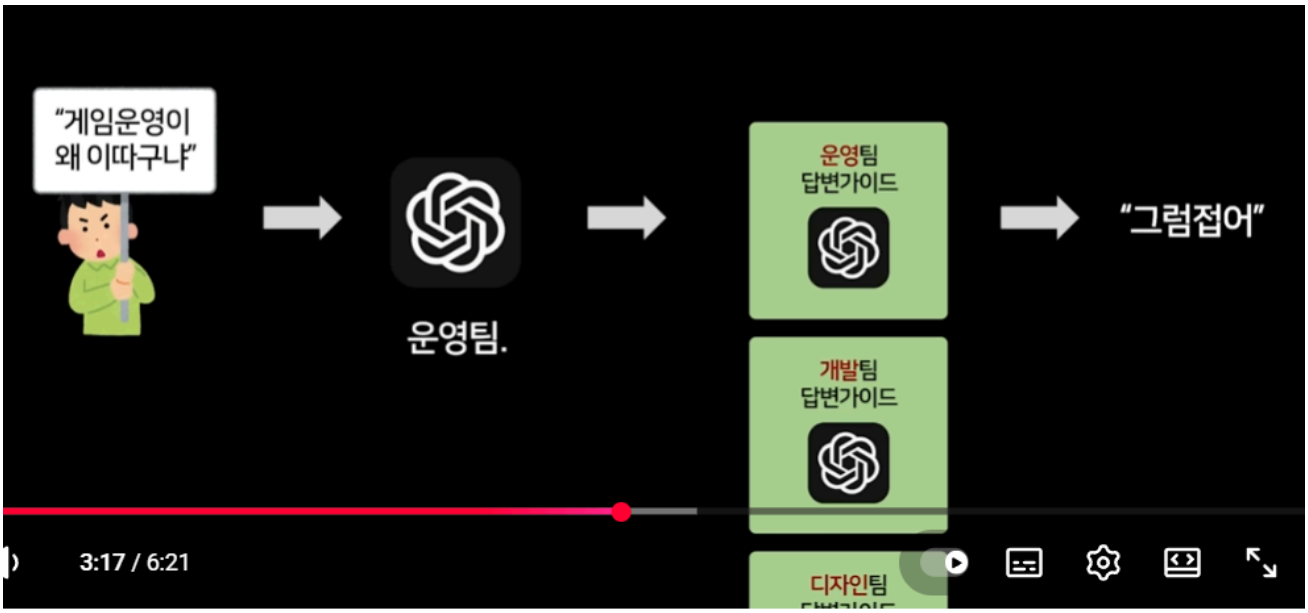

- **트 만드는 기초 기술**
-

parallelization

- 여러 부서의 답변을 전부 받아 짜집기하기

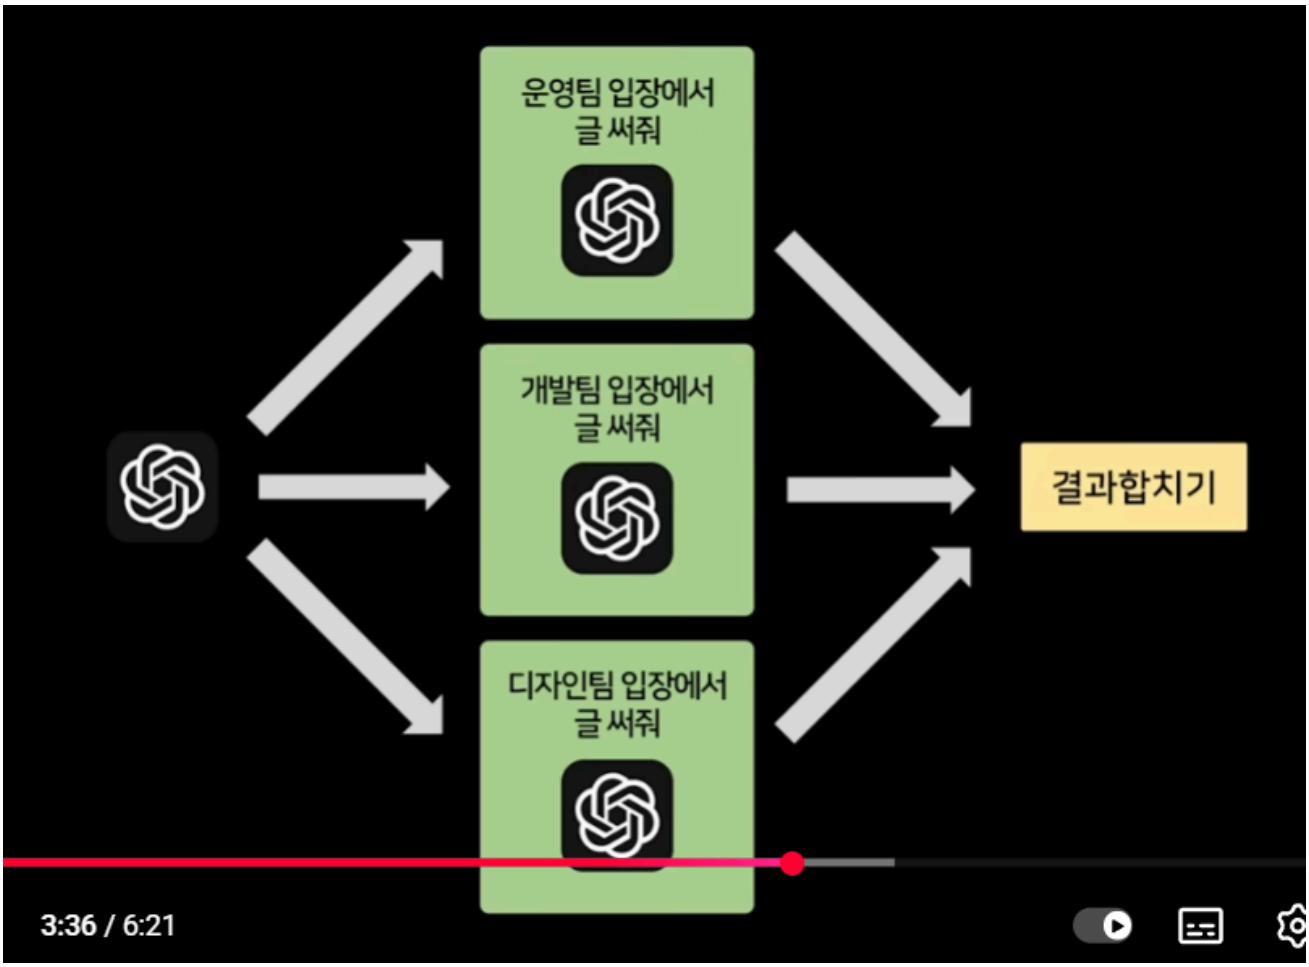

관리자 - 노예 orchestrator worker

- 관리자가 - 필요한 내용들 추론
- 노예 - 각각의 내용들을 각각 수행해서 추론
- 짜집기

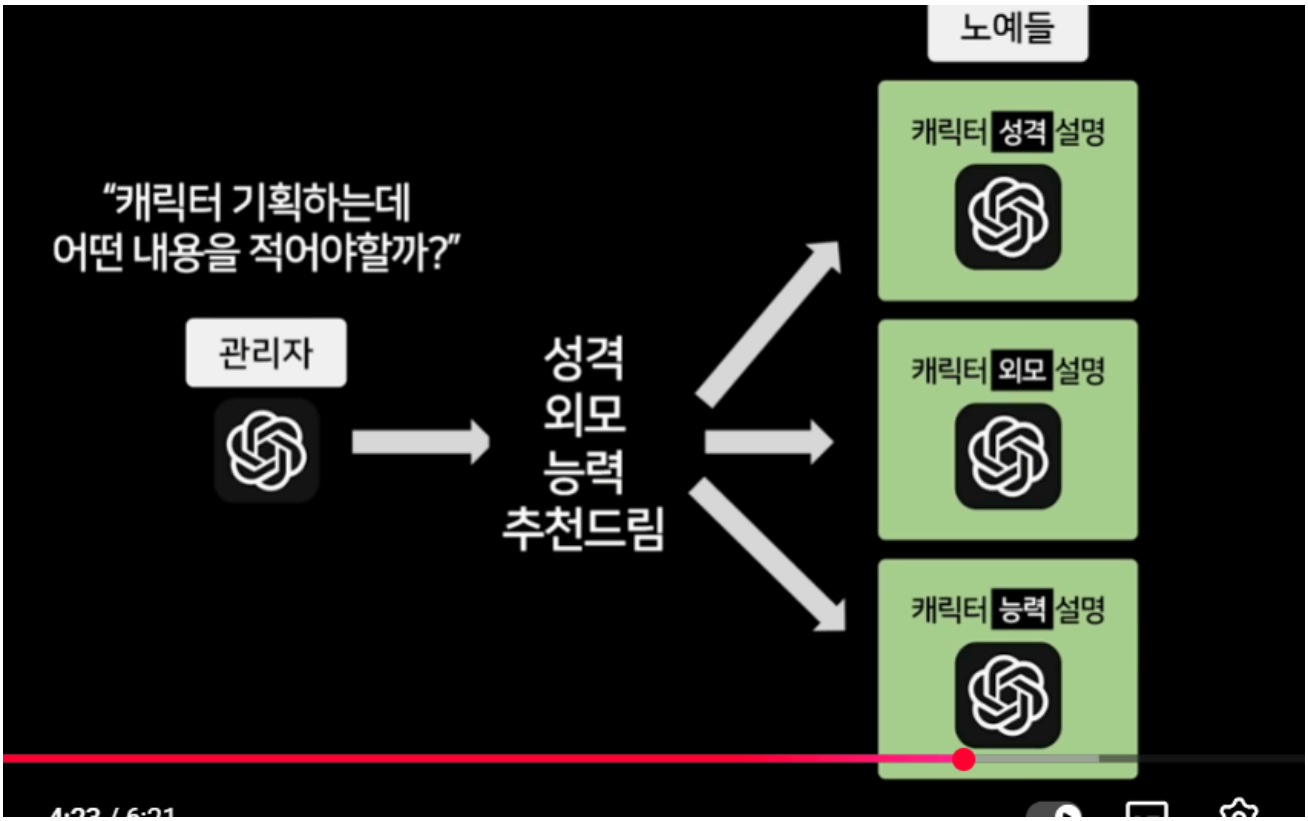

evaluation

- 기준을 정하고 기준에 부합하는지 true false 뺑뺑이

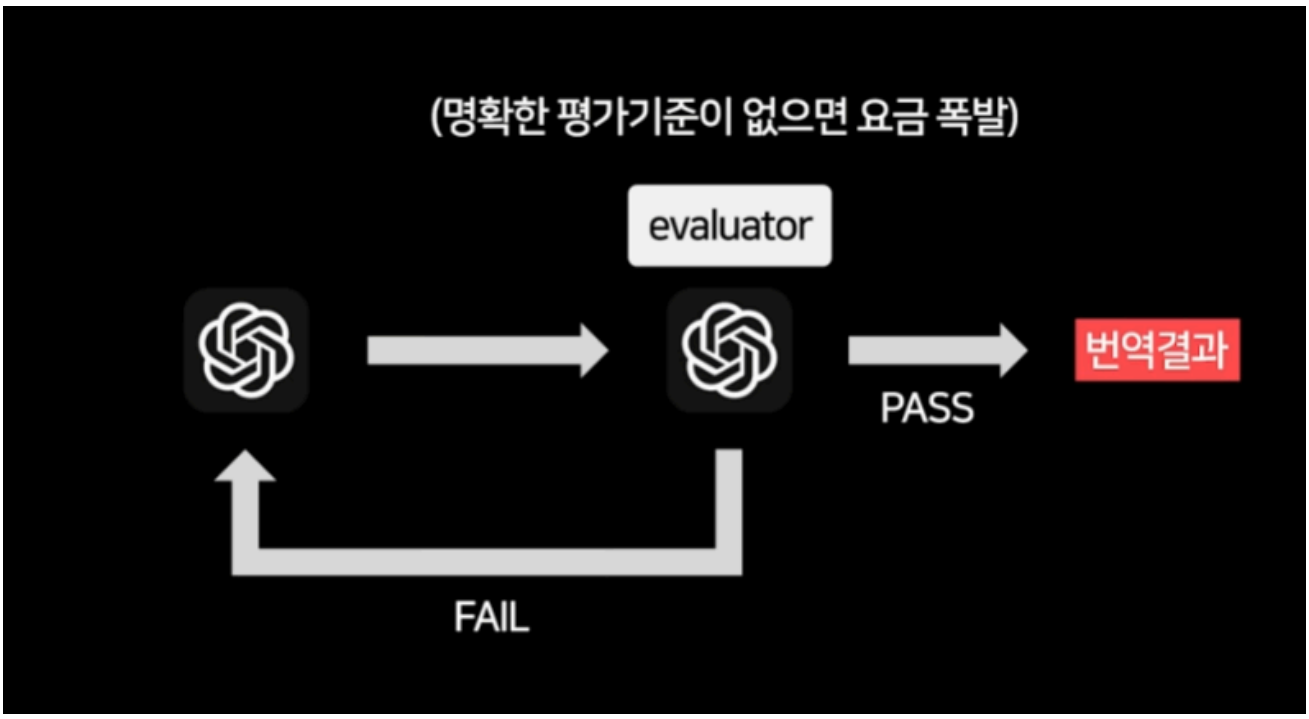

+db출력, db저장, 검색, 메일보내기, json csv로 출력
crewai

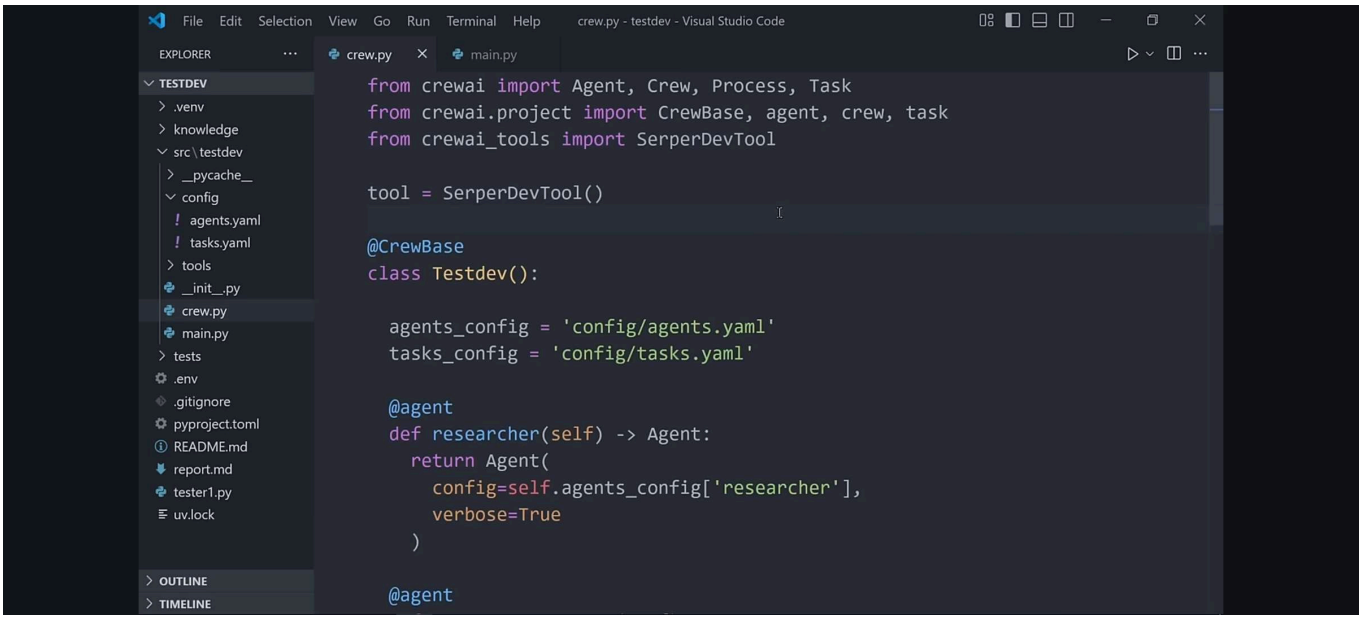

n8n

- langchain과 비슷하지만 얘는 Ai가 아니고 순서 flow를 명시해줘야함
- n8n
  [Trigger: Schedule (매일 9시)]
  ↓
  [HTTP Request: Weather API 호출]
  ↓
  [Function: 메시지 포맷팅]
  ↓
  [Slack Node: 메시지 전송]
  화살표를 만들어 줘야함.
- langchain
  agent.run("회의 요약해서 Notion에 정리해줘")
- lang graph
- **공통점:** 노드(작업)와 엣지(연결)를 **명시적으로 설계**해야 함.
- **차이점:** LangGraph는 **상태(State)** 를 들고 돌고, **LLM이 다음 스텝을 고르게** 하는 **라우터/슈퍼바이저**를 넣을 수 있어 → “고정 플로우 + 유연한 분기” 둘 다 가능.
- 갈수 있는 길을 여러가지 중에 선택할 수 있게 함.
- AI 모델을 불러서 쓰는 자동화 허브 역할
- 워크 플로우 자동화

구분	n8n	AI 모델 (LLM, Agent 등)
역할	작업 자동화, 연결	텍스트/지능 처리
초점	워크플로우, API 호출, 데이터 이동	이해, 추론, 생성

구분	n8n	AI 모델 (LLM, Agent 등)
학습	❌ 학습하지 않음	✅ 사전학습된 언어모델
예시	“매일 요약문 생성하고 메일 보내기”	“요약문 자체를 작성하기”

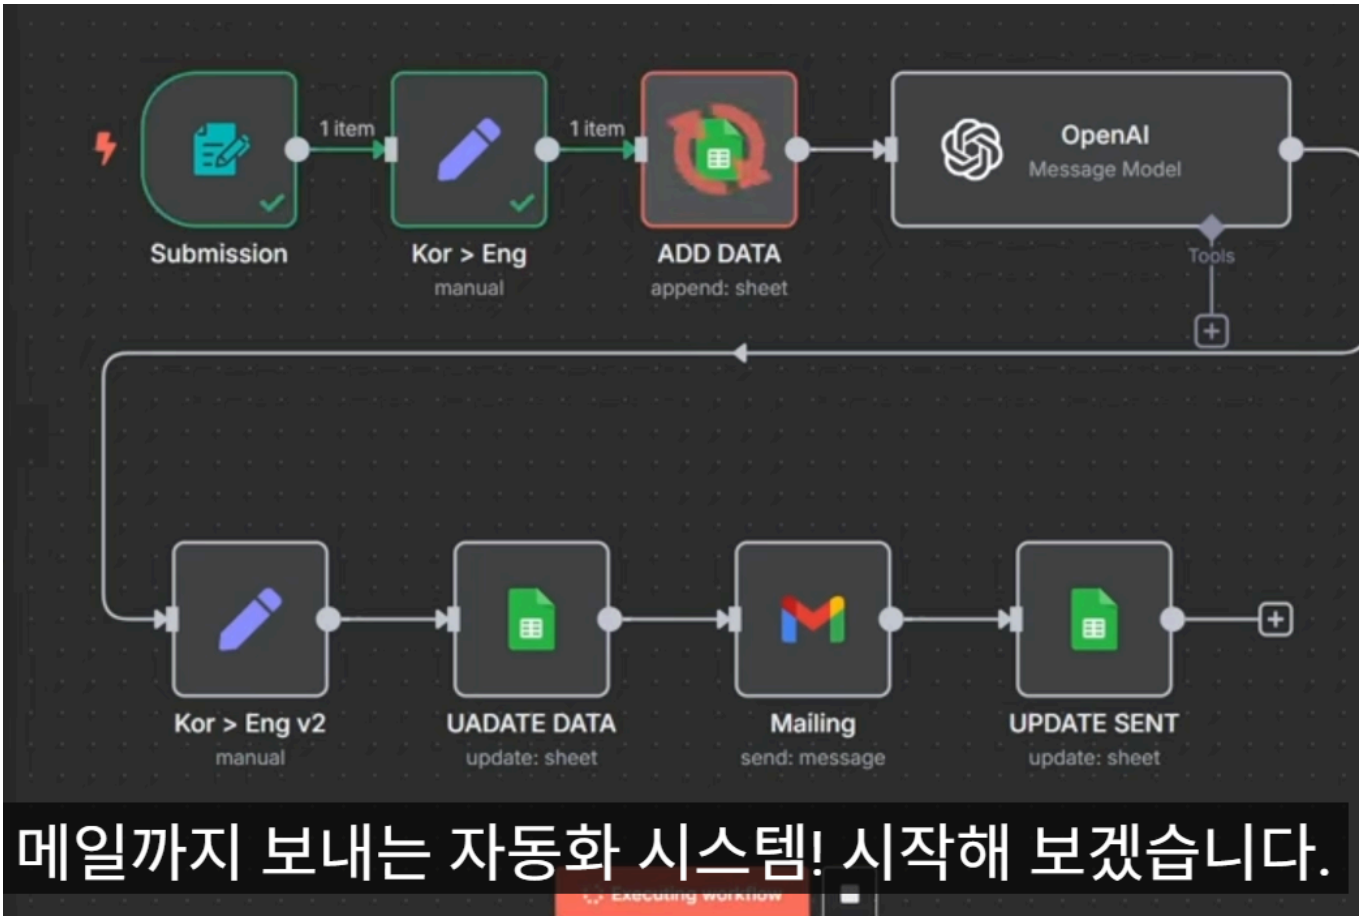

랭체인 랭그래프

- n8n처럼 하는데 체인형태 혹은 그래프 형태

```
import os
import requests
import json


def call_openai(messages, tools=None, tool_results=None):
    resp = requests.post(url, headers=headers, data=json.dumps(payload))
    return resp.json()


def get_weather(city: str) -> str:
    # 진짜로는 날씨 API 호출
    return f"{city}의 날씨는 맑음, 20도입니다."
```

```python
def send_email(to: str, subject: str, body: str) -> str:
    # 진짜로는 이메일 전송 로직
    print(f"[메일 전송] to={to}, subject={subject}\n{body}")
    return "OK"


# ===== 툴 스펙을 LLM에게 알려줄 JSON =====
tool_specs = [
    {
        "type": "function",
        "function": {
            "name": "get_weather",
            "description": "도시 이름을 받아 현재 날씨를 알려준다.",
            "parameters": {
                "type": "object",
                "properties": {
                    "city": {"type": "string"}
                },
                "required": ["city"],
            },
        },
    },
    {
        "type": "function",
        "function": {
            "name": "send_email",
            "description": "이메일을 보낸다.",
            "parameters": {
                "type": "object",
                "properties": {
                    "to": {"type": "string"},
                    "subject": {"type": "string"},
                    "body": {"type": "string"},
                },
                "required": ["to", "subject", "body"],
            },
        },
    },
]


def run_agent(user_input: str):
    messages = [
        {"role": "system", "content": "당신은 유저의 요청을 도와주는 비서입니다."},
        {"role": "user", "content": user_input},
```

```
    ]

    tool_results_messages = []

    while True:
        resp = call_openai(messages!!!, tools=tool_specs!!!!!,
tool_results=tool_results_messages!!!)
        choice = resp["choices"][0]["message"]

        # 툴 호출이 필요한지 확인
        tool_calls = choice.get("tool_calls")
        if not tool_calls:
            # 최종 답변
            print("Assistant:", choice["content"])
            break

        # 여러 개의 tool_call을 순차 실행
        tool_results_messages = []
        for tc in tool_calls:
            fn_name = tc["function"]["name"]
            args = json.loads(tc["function"]["arguments"])

            if fn_name == "get_weather":
                result = get_weather(**args)
            elif fn_name == "send_email":
                result = send_email(**args)
            else:
                result = f"Unknown tool: {fn_name}"

            # tool 결과를 LLM에게 다시 전달
            tool_results_messages.append({
                "role": "tool",
                "tool_call_id": tc["id"],
                "name": fn_name,
                "content": result,
            })

        # messages에 방금 assistant의 tool_calls 메시지도 추가
        messages.append({
            "role": "assistant",
            "content": choice.get("content") or "",
            "tool_calls": tool_calls,
        })
        # 그리고 tool 결과도 같이 보내면서 다시 호출 (위에서 처리)
```

```python
if __name__ == "__main__":
    run_agent("서울 날씨 확인해서, test@example.com 으로 메일 보내줘.")
```

```python
import os
from typing import Optional

from langchain_openai import ChatOpenAI
from langchain_core.tools import tool
from langchain_core.prompts import ChatPromptTemplate
from langchain_core.runnables import RunnablePassthrough
from langchain.agents import create_tool_calling_agent, AgentExecutor

OPENAI_API_KEY = os.environ["OPENAI_API_KEY"]

# ===== 1) LLM 생성 =====
llm = ChatOpenAI(
    model="gpt-4o-mini",
    temperature=0,
    openai_api_key=OPENAI_API_KEY,
)

# ===== 2) LangChain의 "툴" 정의 =====
@tool
def get_weather(city: str) -> str:
    """도시 이름을 받아 현재 날씨를 알려준다."""
    return f"{city}의 날씨는 맑음, 20도입니다."

@tool
def send_email(to: str, subject: str, body: str) -> str:
    """이메일을 보낸다."""
    print(f"[메일 전송] to={to}, subject={subject}\n{body}")
    return "OK"

tools = [get_weather, send_email]

# ===== 3) 프롬프트 템플릿 =====
prompt = ChatPromptTemplate.from_messages(
    [
        ("system", "당신은 유저를 도와주는 비서입니다."),
        ("user", "{input}"),
        ("assistant", "필요하다면 반드시 툴을 사용해서 작업을 수행하세요."),
    ]
)
```

```python
# ===== 4) Agent 만들기 =====
agent = create_tool_calling_agent(llm, tools, prompt)

agent_executor = AgentExecutor(
    agent=agent,
    tools=tools,
    verbose=True,  # 내부 진행 상황 출력
)

def run_agent_langchain(user_input: str):
    result = agent_executor.invoke({"input": user_input})
    # result는 {"input": ..., "output": "..."} 형태
    print("Assistant:", result["output"])


if __name__ == "__main__":
    run_agent_langchain("서울 날씨 확인해서, test@example.com 으로 메일 보내줘.")
```

예시

request

```
{
  "model": "gpt-4o-mini",
  "messages": [
    { "role": "system", "content": "You are a helpful assistant." },
    { "role": "user", "content": "서울 날씨 알려줘" }
  ],
  "tools": [
    {
      "type": "function",
      "function": {
        "name": "get_weather",
        "description": "도시의 날씨를 알려준다.",
        "parameters": {
          "type": "object",
          "properties": { "city": { "type": "string" } },
          "required": ["city"]
        }
      }
    }
  ]
}
```

```
{
  "id": "chatcmpl-abc123",
  "object": "chat.completion",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": null,
        "tool_calls": [
          {
            "id": "call_1",
            "type": "function",
            "function": {
              "name": "get_weather",
              "arguments": "{\"city\": \"서울\"}"
            }
          }
        ]
      },
      "finish_reason": "tool_calls"
    }
  ]
}
```

```
tool_result = get_weather(city="서울")
```

```
{
  "model": "gpt-4o-mini",
  "messages": [
    { "role": "system", "content": "You are a helpful assistant." },
    { "role": "user", "content": "서울 날씨 알려줘" },
    {
      "role": "assistant",
      "content": null,
      "tool_calls": [
        {
          "id": "call_1",
          "type": "function",
          "function": {
            "name": "get_weather",
            "arguments": "{\"city\": \"서울\"}"
          }
        }
```

```
      ]
    },
    {
      "role": "tool",
      "tool_call_id": "call_1",
      "content": "서울의 날씨는 맑고 20도입니다."
    }
  ]
}
```

```
{
  "id": "chatcmpl-final123",
  "object": "chat.completion",
  "choices": [
    {
      "message": {
        "role": "assistant",
        "content": "서울의 날씨는 맑고 20도입니다!"
      },
      "finish_reason": "stop"
    }
  ]
}
```

```
[USER]
   | "서울 날씨 알려줘"
   ▼
[LLM 1차 호출]
   | → tool_call(JSON): get_weather("서울")
   ▼
[서버에서 직접 get_weather 실행]
   | → "서울 맑음 20도"
   ▼
[LLM 2차 호출]
   | tool 결과 전달
   ▼
[LLM 최종 답변]
   | → "서울은 맑고 20도입니다!"
   ▼
[USER]
```

결론

agent ai는 ai 여러대를 사용하는 방식인데, 미리 뭘 호출해야 하고 그 다음 뭘 호출해야하고 이런걸 정하지 않고 main ai가 필요한 툴한테 request하여 결과를 받는 연쇄작용으로 동작

포인트	설명
기억 주체	LLM 자체가 아니라, **messages 리스트**
기억 내용	이전 assistant(tool_calls) + tool 결과 메시지
기억 방식	매번 `chat.completions.create(messages=전체 이력)` 로 전달
한계	토큰 증가 → 요약 or 세션 메모리 필요
대안 도구	LangChain, OpenAI ReAct, CrewAI 등에서 자동 관리 가능

```
from langchain.chains import SimpleSequentialChain
from langchain.llms import OpenAI
from langchain.prompts import PromptTemplate

llm = OpenAI(model="gpt-5")

summarize_prompt = PromptTemplate.from_template("Summarize this
text:\n{text}")
translate_prompt = PromptTemplate.from_template("Translate to
Korean:\n{summary}")

summary_chain = LLMChain(llm=llm, prompt=summarize_prompt)
translate_chain = LLMChain(llm=llm, prompt=translate_prompt)

chain = SimpleSequentialChain(chains=[summary_chain, translate_chain])
result = chain.run("LangChain is a framework that simplifies building LLM
applications.")
print(result)
```

```
핵심
chain = SimpleSequentialChain(chains=[summary_chain, translate_chain])
```

chain에 넣으면 알아서 해준다.

MCP (Model Context Protocol)

- LLM(모델)과 외부 도구·데이터 소스가 상호작용하는 표준 프로토콜
- ai 아님
- LLM이 이미 “이해한 자연어 요청”을 MCP가 “기계 명령(API 호출)”로 바꿔 실행

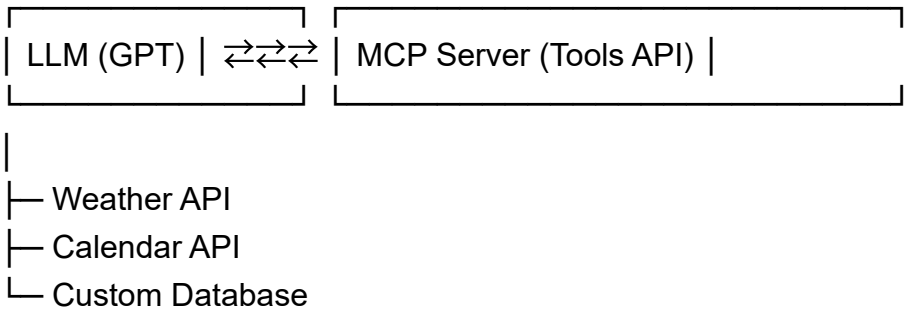

📜 예시 구조

(1) MCP Tool 정의

```
{
  "tools": [
    {
      "name": "get_weather",
      "description": "주어진 지역의 날씨를 반환합니다",
      "input_schema": {
        "type": "object",
        "properties": {
          "location": { "type": "string" },
          "date": { "type": "string" }
        },
        "required": ["location"]
      }
    }
  ]
}
```

(2) LLM이 Tool 호출 요청 (요청 메시지)

```
{
  "type": "tool_use_request",
  "tool_name": "get_weather",
  "arguments": { "location": "부산", "date": "2025-11-08" },
  "request_id": "abc123"
}
```

(3) MCP 서버가 Tool 실행 후 응답

```
{
  "type": "tool_use_result",
  "request_id": "abc123",
```

```
  "output": { "temperature": 18.2, "condition": "맑음" }
}
```

Qwen AI

- 예컨대 Model Studio 국제(싱가포르) 리전 기준으로 “qwen2.5-omni-7b” 모델의 텍스트 입력 토큰 요금이 약 **US$0.10/백만 토큰** 수준이라는 정보가 있습니다. AlibabaCloud+1
- 중국(베이징) 리전 기준으로도 입력/출력 토큰당 요금이 공개되어 있습니다
  https://github.com/QwenLM
  https://huggingface.co/Qwen

```
{
  "model": "qwen2-vl-plus",
  "input": [
    {
      "role": "user",
      "content": [
        {
          "type": "image",
          "image": "..."
        },
        {
          "type": "text",
          "text": "이 이미지에서 텍스트만 OCR 해줘."
        }
      ]
    }
  ]
}
```

OCR은 **Optical Character Recognition**의 약자야.
쉽게 말하면 **이미지 안에 있는 글자를 컴퓨터가 자동으로 읽어서 텍스트로 변환하는 기술**.

이전 CNN or resnet 그런거 지금 -> 트랜스포머

로컬에서 해야함.
ollama
sonnet